

Relatório de Projeto: Sistema de Detecção Automatizada de Sinistros Automotivos

Disciplina: Inteligência Artificial (2026)

Instituição: UniCesumar

Professor: Munif

Equipa: * Felipe Broetto Araujo (RA: 23167564-2)

- Felipe Duarte Milleo Consulim (RA: 23011046-2)

1. Contextualização do tema escolhido

No setor automóvel, especificamente nos segmentos de seguradoras e locadoras de viaturas, o processo de vistoria e identificação de danos na lataria é predominantemente manual. Esta dependência exclusiva da avaliação visual humana gera significativos constrangimentos operacionais, aumenta os custos do processo e abre margem para laudos subjetivos afetados pela fadiga do avaliador. A introdução de técnicas de Visão Computacional surge como uma forte tendência para modernizar e agilizar esta etapa primária de atendimento ao cliente.

2. Problema que será resolvido ou investigado

O problema central desta pesquisa é investigar a viabilidade técnica de automatizar a triagem visual de sinistros veiculares. O objetivo é desenvolver um sistema capaz de processar imagens fotográficas e classificá-las de forma binária em duas categorias exatas: "Inteiros" (sem avarias) ou "Danificados" (com amolgadelas e quebras). Além da viabilidade, procura-se investigar qual modelo clássico de Inteligência Artificial lida melhor com as nuances visuais e artefactos de imagem (como reflexos solares e sombras na chapa metálica).

3. Hipótese da equipa

A nossa hipótese principal é que um modelo capaz de mapear relações não-lineares, como uma Rede Neural Artificial (RNA), apresentará um desempenho preditivo superior ao de um classificador puramente linear, como o Support Vector Machine (SVM). Acreditamos que o SVM terá dificuldade em distinguir reflexos de luz intensos de danos reais, pois ambos alteram bruscamente os valores dos pixéis. Por outro lado, a Rede Neural, através das suas múltiplas camadas ocultas, conseguirá abstrair e isolar as características espaciais complexas que definem uma avaria real.

4. Descrição do dataset utilizado

O dataset utilizado foi construído e curado pela equipa com foco no rigor do treino supervisionado. Para evitar qualquer forma de vazamento de dados (*data leakage*), o conjunto foi estritamente dividido em:

- **Treino:** 206 imagens.
- **Validação:** 191 imagens.
- **Teste:** 192 imagens (usadas apenas na avaliação final às cegas).

Para que os modelos pudessem processar as imagens, aplicou-se um *pipeline* de pré-processamento que incluiu a conversão para tons de cinzentos, o redimensionamento para matrizes de 64x64 pixels e, por fim, o achatamento (*flattening*) para um vetor unidimensional de 4.096 atributos. De forma crucial para o desempenho das redes neurais, aplicou-se a **normalização** dos dados, dividindo todos os valores por 255.0, convertendo os pixels para uma escala contínua de 0 a 1.

5. Métodos de IA utilizados

Em conformidade com a ementa da disciplina, foram utilizados dois algoritmos supervisionados distintos para uma análise comparativa justa:

- **Support Vector Machine - SVM (Aula 007):** Configurado com Kernel Linear, este modelo projeta as 4.096 dimensões num espaço vetorial e procura traçar o hiperplano ótimo que maximize a margem de separação entre as classes. É notoriamente resiliente à "Maldição da Dimensionalidade".
- **Rede Neural Artificial - RNA (Aula 009):** Implementámos um *Multilayer Perceptron (MLP)* com 50 neurónios na camada oculta e mecanismo de paragem antecipada (*early stopping*). A RNA procura padrões complexos através do ajuste estocástico de pesos e vieses ao longo das suas camadas.

6. Avaliação dos modelos

Os modelos foram submetidos de forma independente ao conjunto de Teste (192 imagens inéditas). A síntese dos resultados extraídos das matrizes de confusão e do relatório de classificação é apresentada abaixo:

Desempenho do Modelo SVM (Linear):

- **Acurácia Global:** 82.29%
- Precisão para a classe "Inteiro": 0.91 | Recall: 0.78
- Precisão para a classe "Danificado": 0.73 | Recall: 0.88

Desempenho da Rede Neural Artificial (RNA):

- **Acurácia Global:** 86.46%
- Precisão para a classe "Inteiro": 0.90 | Recall: 0.87
- Precisão para a classe "Danificado": 0.82 | Recall: 0.86

A análise das Curvas ROC geradas pelo sistema demonstrou que a Rede Neural possui uma Área Sob a Curva (AUC) estatisticamente superior, comprovando um maior poder

discriminatório entre classes face a diferentes limiares de confiança.

7. Comparação dos resultados

A avaliação direta das métricas consolida a vitória clara do modelo de **Rede Neural Artificial**, que alcançou 86.46% de acurácia contra 82.29% do SVM.

A diferença crucial entre ambos reside no tratamento dos alarmes falsos (falsos positivos):

- O **SVM** demonstrou uma alta precisão para prever viaturas inteiras (91%), mas apresentou uma falha notória na precisão da classe "Danificado" (apenas 73%). Por ser um classificador rígido (linear), o SVM frequentemente confundiu sombras duras ou reflexos de sol com verdadeiros danos estruturais.
- A **Rede Neural** contornou brilhantemente este problema estatístico. Através do seu aprendizado não-linear, a RNA elevou a precisão da classe "Danificado" de 73% para 82%, mantendo a eficácia de 90% para a classe dos carros inteiros. A capacidade de encontrar limites de decisão complexos permitiu à rede ignorar melhor o ruído ambiente das fotografias, focando-se na textura real do sinistro.

8. Conclusão

O experimento prático validou a hipótese inicial da equipa: algoritmos com capacidade de modelação não-linear, como as Redes Neurais (MLP), são expressivamente superiores na resolução de tarefas de Visão Computacional relacionadas a sinistros. A triagem primária e automatizada de viaturas demonstrou ser exequível, alcançando níveis operacionais seguros (acima de 86% de precisão) quando suportada por uma normalização matemática rigorosa do dataset (ajuste dos tensores para uma escala 0 a 1).

Como direcionamento para trabalhos futuros, propõe-se a substituição do *Multilayer Perceptron* clássico por Redes Neurais Convolucionais (CNNs). Esta atualização dispensará o nivelamento atual dos vetores (*flattening*), permitindo à arquitetura analisar os sinistros mantendo o contexto geométrico e bidimensional das chapas automotivas, o que tenderá a minimizar quase na totalidade os alarmes falsos causados pela iluminação exterior.