

Relatório de Projeto: Sistema de Detecção de Sinistros Automotivos

Disciplina: Inteligência Artificial (2026) – UniCesumar

Professor: Munif

Equipe: Felipe Broetto Araujo (RA: 23167564-2) e Felipe Duarte Milleo Consulim (RA: 23011046-2)

1. Contextualização do tema escolhido

O setor automotivo, especificamente os segmentos de seguros, concessionárias e locadoras de veículos (rent-a-car), lida diariamente com um alto volume de vistorias veiculares. Tradicionalmente, a identificação de danos na lataria é um processo manual, dependente da avaliação visual de peritos humanos. Esse fluxo gera gargalos operacionais, aumenta o tempo de espera do cliente e abre margem para laudos subjetivos ou inconsistentes.

2. Problema que será resolvido ou investigado

Como automatizar e acelerar a triagem visual primária de veículos sinistrados? O problema central deste projeto é investigar a viabilidade de aplicar algoritmos clássicos de Inteligência Artificial e Visão Computacional para processar imagens fotográficas de veículos e classificá-las de forma dicotômica (binária) em duas categorias exatas: "Inteiros" (sem avarias) ou "Danificados" (com amassados, arranhões ou quebras).

3. Hipótese da equipe

A nossa hipótese principal é que um modelo de **Aprendizagem Supervisionada (SVM)**, atuando sobre imagens convertidas em vetores numéricos unidimensionais, é capaz de encontrar um hiperplano separador com acurácia satisfatória (>70%) para atuar como um filtro primário de vistoria.

Como hipótese secundária, acreditamos que um modelo de **Aprendizagem Não Supervisionada (K-Means)** falhará ao tentar isolar as imagens de danos por conta própria. Acreditamos que a máquina, sem gabarito, agrupará as imagens por semelhanças de iluminação e reflexos, provando a necessidade estrita de supervisão humana (rótulos) para resolver esse problema matemático.

4. Descrição do dataset utilizado

O dataset utilizado foi construído e curado organicamente pela equipe, focado no balanceamento e na extração de características reais do dia a dia.

- **Divisão de Pastas:** Para evitar o vazamento de dados (*data leakage*), o dataset foi rigidamente dividido em:
 - **Treino:** 301 imagens (Onde o modelo aprende os pesos).
 - **Validação:** 184 imagens (Onde calibramos o sistema).
 - **Teste:** 215 imagens (Dados isolados e inéditos para a prova final).
- **Pré-Processamento (Pipeline):** Como algoritmos clássicos não compreendem imagens brutas em formato RGB, aplicamos um pipeline de conversão:
 1. Conversão para tons de cinza (redução de ruído de cor).
 2. Redimensionamento padronizado para matrizes de 64x64 pixels.
 3. Achatamento (*Flattening*) das matrizes, convertendo as imagens 2D em um vetor unidimensional de **4.096 atributos (features)** numéricas contínuas.

5. Métodos de IA utilizados

Para cumprir as exigências da disciplina e garantir uma análise híbrida, aplicamos dois métodos sob diferentes paradigmas de aprendizagem:

- **Modelo Preditivo (SVM - Support Vector Machine):** Algoritmo de **Aprendizagem Supervisionada**. Escolhemos o Kernel Linear para atuar sobre as 4.096 dimensões da imagem. O SVM é matematicamente blindado contra overfitting em cenários de alta dimensionalidade ("Maldição da Dimensionalidade"), tornando-o ideal para classificar (prever) se a imagem nova pertence ao grupo de veículos inteiros ou danificados.
- **Modelo Descritivo (K-Means):** Algoritmo de **Aprendizagem Não Supervisionada**. Configurado para encontrar $k=2$ agrupamentos (clusters). Ele opera de forma exploratória, agrupando os vetores de imagens pela menor Distância Euclidiana, sem que o modelo saiba previamente a resposta (rótulo).

6. Avaliação dos modelos

O sistema foi submetido ao conjunto de Teste (215 imagens nunca vistas). O modelo preditivo atingiu uma **Acurácia Global de 74.88%**.

Abaixo, apresentamos o painel gráfico de desempenho:

(Insira aqui a imagem trabalhoia.png com a Matriz de Confusão, Gráfico PCA, Curva ROC e Precision-Recall)

- **Matriz de Confusão (SVM):** Demonstra alta capacidade de acertar carros inteiros (verdadeiros negativos), com a ocorrência de alguns alarmes falsos (carros inteiros previstos como batidos).
- **Dispersão PCA (K-Means):** O gráfico de clusters revela forte sobreposição matemática entre os dois grupos.
- **Curvas ROC e PR:** Com área sob a curva (AUC) de 0.87, o modelo possui uma sensibilidade e especificidade vastamente superiores a um classificador aleatório, sustentando a sua validade preditiva.

7. Comparação dos resultados

O contraste entre os dois métodos revelou a verdadeira natureza dos nossos dados:

- O **SVM (Supervisionado)** demonstrou sucesso prático. Com uma precisão de 92% para carros inteiros, ele se provou uma excelente ferramenta de "filtro verde" – se o SVM afirmar que o carro está intacto, a seguradora pode aprovar a vistoria automaticamente com altíssima confiança.
- Em contrapartida, o **K-Means (Não Supervisionado)** apresentou um Índice Silhouette muito baixo (0.229). Como havíamos hipotetizado, a máquina sozinha não entende o conceito de "amassado". Para a matemática do agrupamento, o reflexo agressivo da luz do sol na lataria possui valores de pixels idênticos ao de um buraco na chapa. Logo, o K-Means agrupa sombras com amassados.
- **Veredito:** A detecção visual de sinistros exige obrigatoriamente a presença de rótulos humanos (supervisão) para delinear o hiperplano de separação correto.

8. Conclusão

O projeto alcançou o seu objetivo ao desenvolver um MVP viável e estruturado para a automação de vistorias automotivas. Demonstramos que um pipeline simples (Achatamento + SVM Linear) é suficiente para criar uma triagem rápida, econômica e matematicamente confiável (~75% de acurácia em mundo real).

Como evolução tecnológica (Trabalhos Futuros), a limitação causada pelos alarmes falsos em sombras e reflexos aponta para a necessidade de substituir o classificador linear clássico por Redes Neurais Convolucionais (CNNs). As CNNs eliminam a etapa de achatamento (*flattening*), analisando as imagens em 2D e extraindo características de bordas e texturas em múltiplas camadas, o que garantirá uma compreensão espacial profunda das anomalias na lataria.